

Wstęp do Uczenia Maszynowego 2026Z

PROJEKT 1

1 Wstęp

Celem niniejszego projektu jest opracowanie oraz wdrożenie kompletnego procesu uczenia maszynowego dla problemu klasyfikacji binarnej. Głównym zadaniem jest zbudowanie modelu predykcyjnego charakteryzującego się jak największą mocą predykcyjną na nowych danych. Zbiór treningowy oraz etykiety do zbioru treningowego należy wykorzystać do przygotowania modelu. Oczekiwany wynik to wektor prawdopodobieństw przynależności do klasy 1 dla obserwacji ze zbioru testowego.

1.1 Opis zbioru danych

Dane do projektu to zbiór zawierający informacje o klientach kart kredytowych, ich cechach demograficznych oraz historii spłat zadłużenia z okresu sześciu miesięcy.

Zmienną docelową (**y_train**) w analizowanym problemie jest binarna flaga informująca o tym, czy dany klient popadł w zwłokę z płatnością w kolejnym miesiącu:

- **1** – klient nie wywiązał się z płatności (brak spłaty w terminie),
- **0** – klient wywiązał się z płatności (spłata terminowa).

Poniższa tabela przedstawia szczegółowy opis poszczególnych kolumn znajdujących się w zbiorze **X_train** i **X_test**.

Nazwa zmiennej	Opis zmiennej
LIMIT_BAL	Wysokość przyznanego limitu kredytowego.
SEX	Płeć klienta: 1 = mężczyzna, 2 = kobieta.
EDUCATION	Poziom wykształcenia: 1 = magister/doktor; 2 = licencjat; 3 = średnie; 0, 4, 5, 6 = inne.
MARRIAGE	Stan cywilny: 1 = w związku małżeńskim; 2 = stan wolny; 0, 3 = inne.
AGE	Wiek klienta w latach.
PAY_0 – PAY_6	Historia statusu spłaty zadłużenia w kolejnych miesiącach (PAY_0 – najświeższy miesiąc, PAY_6 – sprzed 6 miesięcy). Wartości określają terminowość spłaty lub wymiar opóźnienia.
BILL_AMT1 – BILL_AMT6	Kwota miesięcznego wyciągu/rachunku w kolejnych miesiącach (BILL_AMT1 – najświeższy wyciąg, BILL_AMT6 – sprzed 6 miesięcy).
PAY_AMT1 – PAY_AMT6	Kwota wpłaty dokonana przez klienta w danym miesiącu na poczet zadłużenia (PAY_AMT1 – najświeższa wpłata, PAY_AMT6 – sprzed 6 miesięcy).

W ramach projektu dostępne są następujące pliki:

- zbiór treningowy: **X_train.csv**,
- etykiety zbioru treningowego: **y_train.csv**,
- zbiór testowy: **X_test.csv**.

Aby wczytać zbiór danych w języku Python, wystarczy użyć funkcji **read_csv** z biblioteki **pandas**.

1.2 Struktura i kamienie milowe projektu

Łączna liczba punktów do zdobycia za Projekt 1 wynosi 52 punkty. Prace nad projektem jest podzielona na trzy kluczowe etapy, które będą oceniane niezależnie:

1. **Kamień milowy 1 – Eksploracja danych, przygotowanie i strojenie modelu drzewa (Tydzień 5, 12 punktów):** Przeprowadzenie eksploracyjnej analizy danych, ocena rozkładów zmiennych, identyfikacja braków danych oraz wartości odstających, zdefiniowanie i uzasadnienie wyboru odpowiedniej metryki ewaluacji dostosowanej do specyfiki problemu, przygotowanie wstępnego podziału danych na zbiory treningowy, testowy i/lub walidacyjny oraz wybór i optymalizacja hiperparametrów modelu drzewa decyzyjnego.
2. **Kamień milowy 2 – Pipeline i modele bazowe (Tydzień 8, 12 punktów):** Stworzenie automatycznej ścieżki przetwarzania danych (*pipeline*) korygującej zidentyfikowane usterki zbioru. Wytrenowanie oraz zoptymalizowanie dwóch klasyfikatorów: modelu drzewa decyzyjnego oraz alternatywnego modelu z innej rodziny algorytmów uczenia maszynowego. Porównanie ich wyników na podstawie wybranej metryki.
3. **Oddanie końcowe projektu (Tydzień 12, 28 punktów):** Opracowanie ostatecznego modelu predykcyjnego, przygotowanie zbiorczego raportu podsumowującego wykonane prace.

⚠ Ważne: Projekt wykonywany jest całkowicie **samodzielnie**.

1.3 Szablony raportów

W celu usprawnienia procesu przygotowywania sprawozdań oraz zapewnienia spójności dokumentacji, udostępnione zostały dedykowane szablony plików dla każdego z etapów projektu (*Kamień milowy 1*, *Kamień milowy 2* oraz *Oddanie końcowe*):

- **Szablon LaTeX (.tex):** Dedykowany szablon do wygenerowania raportu w formacie .pdf. Zawiera przygotowaną strukturę sekcji, nagłówki oraz skonfigurowany układ stron.
- **Szablon Jupyter Notebook (.ipynb):** Gotowy plik Notatnika Jupyter, w którym należy przeprowadzić eksperymenty, analizę danych oraz kodowanie modeli.

⚠ Ważne: Szablony raportów LaTeX (.tex) oraz Jupyter Notebook (.ipynb) są dostępne w plikach zespołu na MS Teams.

2 Kamień milowy 1 – Eksploracja danych, przygotowanie i strojenie modelu (Tydzień 5, 12 punktów)

2.1 Zadanie i kryteria oceniania

Głównym celem pierwszego etapu jest dogłębne zrozumienie struktury zbioru danych oraz właściwe przygotowanie go do dalszych związanych z modelowaniem. Zakres prac oraz odpowiadające im kryteria oceny są następujące:

1. Eksploracyjna analiza danych (2 punkty):
 - Statystyki opisowe i rozkłady zmiennych,
 - Analiza wartości brakujących,
 - Wykrywanie wartości odstających (*outliers*),
 - Analiza relacji i istotności zmiennych.
2. Metryka ewaluacji oraz podział danych (2 punkty)
 - Wybór i uzasadnienie metryki,

- Strategia podziału zbioru.
3. Optymalizacja hiperparametrów modelu drzewa (4 punkty):
- Wybór 2 – 3 kluczowych hiperparametrów drzewa decyzyjnego oraz zdefiniowanie i dobór punktów w przestrzeni hiperparametrów,
 - Przeprowadzenie eksperymentów i ocena wpływu hiperparametrów na wybraną metrykę.
4. Jakość raportu i notatnika Jupyter Notebook (2 punkty)
- Jupyter Notebook (.ipynb)
Czytelny, w pełni uruchamialny i ustrukturyzowany kod z wykresami oraz komentarzami zawierający punkty 1, 2 i 3.
 - Raport (.pdf)
Przygotowanie raportu podsumowującego najważniejsze wnioski z punktów 1, 2 i 3.
⚠ Ważne: Raport maksymalnie 2 strony A4 według udostępnionego szablonu.
5. Obrona i dyskusja (2 punkty)
- Krótka odpowiedź ustna podczas zajęć, obejmująca obronę podjętych decyzji analitycznych, interpretację wykresów, uzasadnienie wybranej metodyki podziału i ewaluacji oraz wybór hiperparametrów i ich przestrzeni do optymalizacji modelu drzewa.

2.2 Weryfikacja

Ocena za *Kamień milowy 1* przyznawana jest na podstawie przesłanych materiałów oraz krótkiego odpytania z przygotowanego raportu przez prowadzącego podczas zajęć laboratoryjnych.

2.3 Wymagane pliki i forma oddania

Rozwiązanie należy wgrać jako dwa pliki o **identycznej nazwie** IN_GR_KIER_Nazwisko.Imie.KM1:

1. .ipynb – notatnik Jupyter Notebook zawierający pełny, wykonany i czytelny kod wraz z wykresami i komentarzami,
2. .pdf – krótki raport stanowiący podsumowanie analizy (**maksymalnie 2 strony A4**).

Nazwę IN_GR_KIER_Nazwisko.Imie.KM1 należy utworzyć zgodnie ze schematem:

$$IN = \begin{cases} AK, & \text{grupa Anny Kozak,} \\ MK, & \text{grupa Mateusza Krzyżińskiego,} \\ KW, & \text{grupa Katarzyny Woźnicy.} \end{cases}$$

gdzie GR $\in \{11, 12, 21, 22, 31\}$ oznacza numer grupy zajęciowej z USOS, a KIER $\in \{IAD, MAD\}$.

⚠ Ważne: Pliki należy umieścić w zadaniu *Kamień milowy 1* w zespole na MS Teams.

⚠ Ważne: Prace, które **nie będą przygotowane** w odpowiednim formacie lub z poprawną nazwą, **nie będą oceniane**.

2.4 Termin przesłania rozwiązania – 30.09.2026 (do 23:59)

2.5 Terminy odpytania (podczas zajęć lab)

	MAD 11	MAD 12	MAD 21	MAD 22	IAD 11	IAD 12	IAD 21	IAD 22	IAD 31
KM 1	04.11.	04.11.	05.11.	05.11.	05.11.	05.11.	04.11.	04.11.	05.11.

3 Kamień milowy 2 – Pipeline i modele bazowe (Tydzień 8, 12 punktów)

3.1 Zadanie i kryteria oceniania

Głównym celem drugiego etapu jest stworzenie działającej ścieżki przetwarzania (*pipeline*) oraz podstawowego punktu odniesienia (*baseline*), uwzględniających wnioski i obserwacje z analizy danych przeprowadzonej w ramach *Kamienia milowego 1*. Zakres prac oraz odpowiadające im kryteria oceny są następujące:

1. Ścieżka przetwarzania danych (*pipeline*) (2 punkty):
 - Przygotowanie w języku Python automatycznego potoku przetwarzania danych (*pipeline*),
 - Rozwiązanie zidentyfikowanych problemów i usterek zbioru danych na podstawie obserwacji z *Kamienia milowego 1*.
2. Model drzewa decyzyjnego (2 punkty):
 - Wytrenowanie klasyfikatora opartego na drzewie decyzyjnym z wykorzystaniem przygotowanego *pipeline'u*,
 - Przeprowadzenie optymalizacji hiperparametrów modelu (należy rozważyć minimum 2 różne hiperparametry).
3. Alternatywny model uczenia maszynowego (2 punkty):
 - Wytrenowanie drugiego modelu pochodzącego z innej rodziny algorytmów niż drzewa decyzyjne,
 - Przeprowadzenie optymalizacji hiperparametrów alternatywnego klasyfikatora (należy rozważyć minimum 2 różne hiperparametry).
4. Ewaluacja i porównanie wyników (2 punkty):
 - Ewaluacja obydwu wytrenowanych modeli z użyciem metryki ustalonej w *Kamieniu milowym 1*,
 - Przedstawienie, porównanie oraz podsumowanie uzyskanych rezultatów.
5. Jakość raportu i notatnika Jupyter Notebook (2 punkty)
 - Jupyter Notebook (*.ipynb*)
Czytelny, w pełni uruchamialny i ustrukturyzowany kod z wykresami oraz komentarzami zawierający czytelne przetwarzanie danych, trenowanie i optymalizację modeli.
 - Raport (*.pdf*)
Przygotowanie raportu podsumowującego architekturę *pipeline'u*, wybrane hiperparametry oraz porównanie wyników.
⚠ Ważne: Raport maksymalnie 2 strony A4 według udostępnionego szablonu.
6. Obrona i dyskusja (2 punkt)
 - Krótka odpowiedź ustna podczas zajęć, obejmująca obronę podjętych decyzji analitycznych, interpretację wykresów oraz uzasadnienie wybranej metodyki podziału i ewaluacji.

3.2 Wymagane pliki i forma oddania

Rozwiązanie należy wgrać jako dwa pliki o **identycznej nazwie** IN_GR_KIER_Nazwisko.Imie_KM2:

1. *.ipynb* – notatnik Jupyter Notebook zawierający pełny, wykonany i czytelny kod wraz z wykresami i komentarzami,
2. *.pdf* – krótki raport stanowiący podsumowanie analizy (maksymalnie **2 strony A4**).

Nazwę `IN_GR_KIER_Nazwisko_Imie_KM2` należy utworzyć zgodnie ze schematem:

$$IN = \begin{cases} AK, & \text{grupa Anny Kozak,} \\ MK, & \text{grupa Mateusza Krzyżńskiego,} \\ KW, & \text{grupa Katarzyny Woźnicy.} \end{cases}$$

gdzie $GR \in \{11, 12, 21, 22, 31\}$ oznacza numer grupy zajęciowej z USOS, a $KIER \in \{IAD, MAD\}$.

▲ Ważne: Pliki należy umieścić w zadaniu *Kamień milowy 2* w zespole na MS Teams.

▲ Ważne: Prace, które **nie będą przygotowane** w odpowiednim formacie lub z poprawną nazwą, **nie będą oceniane**.

3.3 Weryfikacja

Ocena za *Kamień milowy 2* przyznawana jest na podstawie przesłanych materiałów oraz krótkiego odpytania z przygotowanego raportu przez prowadzącego podczas zajęć.

3.4 Termin przesłania rozwiązania – 20.11.2026 (do 23:59)

3.5 Terminy odpytania (*podczas zajęć lab*)

Etap	MAD 11	MAD 12	MAD 21	MAD 22	IAD 11	IAD 12	IAD 21	IAD 22	IAD 31
KM 2	25.11.	25.11.	26.11.	26.11.	26.11.	26.11.	25.11.	25.11.	26.11.

4 Oddanie końcowe projektu (Tydzień 12, 28 punktów)

4.1 Zadanie i kryteria oceniania

Głównym celem ostatniego etapu jest synteza najważniejszych wniosków z *Kamienia milowego 1* i *2*, przetestowanie zaawansowanych podejść i nowych modeli oraz przeprowadzenie kompleksowej oceny jakości ostatecznego rozwiązania predykcyjnego. Zakres prac oraz odpowiadające im kryteria oceny są następujące:

1. Synteza, inżynieria cech i zaawansowane modelowanie (4 punkty):
 - Uwzględnienie i synteza najważniejszych obserwacji z *Kamienia milowego 1* oraz *2*,
 - Wdrożenie nowych podejść badawczych,
 - Wytrenowanie i optymalizacja nowych, zaawansowanych modeli.
2. Ocena jakości i ewaluacja końcowa modeli (6 punktów):
 - Dogłębna ocena jakości ostatecznego modelu
 - Analiza macierzy pomyłek oraz wykreślenie i interpretacja krzywych ROC i *Precision-Recall*
 - Analiza błędów klasyfikacji i ocena zdolności uogólniania modelu na nowych danych
3. Jakość kodu i notatnika Jupyter Notebook (4 punkty):
 - Jupyter Notebook (`.ipynb`)
Ustrukturyzowany, czytelny i w pełni powtarzalny kod realizujący kompletny proces uczenia maszynowego *end-to-end* (od wczytania danych po finalne predykcje).
4. Raport końcowy (6 punktów):
 - Raport (`.pdf`)
Kompleksowe sprawozdanie podsumowujące pełny cykl życia projektu, zestawienie i porównanie wszystkich przetestowanych modeli oraz uzasadnienie wyboru ostatecznego rozwiązania.
 - ▲ Ważne:** Raport maksymalnie 4 strony według udostępnionego szablonu.

5. Obrona końcowa i dyskusja (4 punkty):

- Odpowiedź ustna, obejmująca obronę podjętych decyzji, uzasadnienie zastosowanych metod oraz dyskusję nad ograniczeniami rozwiązania.

6. Jakość predykcji na zbiorze testowym (4 punkty):

- Jakość predykcji oceniana miarą $\mathcal{M}$ na zbiorze testowym. Wyniki zostaną ustawione w ranking (od najlepszego do najgorszego). Osoba z najlepszym wynikiem według miary $\mathcal{M}$ zyskuje 4 punktów. Osoba z najgorszym wynikiem zyskuje 2 punkty. Pozostałe wyniki zostaną przeskalowane i zaokrąglone do wartości 0.1.

Miara $\mathcal{M}$ zostanie podana po oddaniu części *Kamień milowy 2*.

4.2 Wymagane pliki i forma oddania

Rozwiązanie należy wgrać jako trzy pliki o **identycznej nazwie** `IN_GR_KIER_Nazwisko.Imie.FINAL`:

1. `.ipynb` – notatnik Jupyter Notebook zawierający pełny, wykonany i czytelny kod wraz z wykresami i komentarzami,
2. `.pdf` – raport stanowiący podsumowanie projektu (maksymalnie **4 strony A4**).
3. `.txt` – prawdopodobieństwa przynależności do klasy 1 dla danych testowych (przy założeniu progu odcięcia równym 0.5).

Nazwę `IN_GR_KIER_Nazwisko.Imie.FINAL` należy utworzyć zgodnie ze schematem:

$$IN = \begin{cases} AK, & \text{grupa Anny Kozak,} \\ MK, & \text{grupa Mateusza Krzyżńskiego,} \\ KW, & \text{grupa Katarzyny Woźnicy.} \end{cases}$$

gdzie $GR \in \{11, 12, 21, 22, 31\}$ oznacza numer grupy zajęciowej z USOS, a $KIER \in \{IAD, MAD\}$.

⚠ Ważne: Pliki należy umieścić w zadaniu *Oddanie projektu* w zespole na MS Teams.

⚠ Ważne: Prace, które **nie będą przygotowane** w odpowiednim formacie lub z poprawną nazwą, **nie będą oceniane**.

4.3 Weryfikacja

Ocena za *Oddanie projektu* przyznawana jest na podstawie przesłanych materiałów oraz krótkiego odpytania z przygotowanego raportu przez prowadzącego podczas zajęć.

4.4 Termin przesłania rozwiązania – 07.01.2027 (do 23:59)

4.5 Terminy odpytania (*podczas zajęć lab*)

Etap	MAD 11	MAD 12	MAD 21	MAD 22	IAD 11	IAD 12	IAD 21	IAD 22	IAD 31
OP	13.01	13.01	14.01	14.01	14.01	14.01	13.01	13.01	14.01